

**Semantička segmentacija mamografskih slika na osnovu
recepta datog na [https://github.com/qubvel-org/
segmentation_models.pytorch](https://github.com/qubvel-org/segmentation_models.pytorch) (UNet++)**

Principi dubokog učenja

Teodora Todorović E9 2/2025

1. Uvod

Mamografija je danas najčešće korišćena metoda skrininga dojke. Njena osnovna prednost je mogućnost da se suptilne promene u tkivu dojke uoče rano, ali tumačenje mamograma zahteva veliko iskustvo radiologa i podložno je subjektivnosti, zamoru i razlikama u proceni između različitih posmatrača.

Mase spadaju među najznačajnije radiološke nalaze na mamogramu koji mogu ukazivati na prisustvo tumora. Njihova automatska segmentacija, odnosno precizno određivanje kojim pikselima na slici pripada masa, a ne samo detekcija njenog postojanja i lokacije, predstavlja važan korak ka razvoju sistema za kompjuterski potpomognutu dijagnostiku. Segmentacija na nivou piksela omogućava dalju kvantitativnu analizu oblika, veličine, granica i teksture mase, a to su parametri od direktnog kliničkog značaja za procenu da li je tumor benigni ili maligni.

Segmentacija masa u mamografiji nailazi na više problema. Mase zauzimaju mali deo površine slike, što dovodi do izražene neuravnoteženosti klasa između piksela mase i pozadine. Granice masa su često difuzne, neoštre ili maskirane gustim žlezdanim tkivom, posebno kod žena sa gušćim dojkama. Takođe, baze podataka sa pouzdanim ekspertskim anotacijama su po pravilu male, jer je proces anotiranja spor, skup i zahteva angažovanje radiologa. Izgled, oblik i veličina masa variraju u velikoj meri, od malih, dobro ograničenih čvorova do velikih, neregularnih i slabo kontrastnih formacija. Kao što će se videti u nastavku rada, upravo ova kombinacija malog skupa podataka, gde dodatno više slika pripada jednom pacijentu i velike varijabilnosti veličine masa presudno uticala na to gde model najviše greši.

U ovom radu razmatra se primena i prilagođavanje arhitekture UNet++ [1], i njena implementacija u biblioteci `segmentation_models.pytorch` [2], na zadatak segmentacije masa na bazi mamografskih snimaka INBreast [3]. Cilj rada je da se ispita kako se gotov recept za semantičku segmentaciju iz pomenute biblioteke prilagođava mamogramima (jednokanalni, sivi snimci visoke dinamike, mala baza, jak disbalans klasa).


2. Metode i materijali

2.1 Izabrani model

Za segmentaciju je korišćena arhitektura UNet++, koju su predložili Zhou, Rahman Siddiquee, Tajbakhsh i Liang u radu iz 2018. godine, kao unapređenje klasične U-Net arhitekture za segmentaciju medicinskih slika. Standardni U-Net povezuje enkoder i dekoder direktnim (skip) vezama na svakom nivou rezolucije, pri čemu se karakteristike iz enkodera prosleđuju odgovarajućem nivou dekodera bez ikakve dodatne obrade. Autori UNet++ arhitekture ovaj pristup smatraju problematičnim zbog semantičkog jaza između karakteristika enkodera, koje su na nižim nivoima mreže još uvek gruba, plitka reprezentacija, i karakteristika dekodera na istom nivou, koje su rezultat dubljih, semantički bogatijih transformacija. Njihova polazna teza je da optimizator ima lakši zadatak kada su karakteristike koje se spajaju već međusobno semantički slične, umesto da mreža mora sama, u hodu, da premosti tu razliku.

Rešenje koje predlažu jesu ugnježdjeni, gusto povezani putevi između enkodera i dekodera. Umesto da se karakteristika iz enkodera direktno prosledi dekoderu, ona prvo prolazi kroz niz međublokova organizovanih u obliku piramide, gde se u svakom čvoru spajaju izlazi iz prethodnih čvorova istog nivoa i uzorkovan naviše izlaz iz dubljeg nivoa. Na slici 1 je prikazana ova ideja onako kako je predstavljena u originalnom radu: čvorovi $X_{i,j}$ predstavljaju konvolucione blokove, isprekidane strelice označavaju skip veze, a pune strelice naviše i naniže označavaju

uzorkovanje. Konkretno, semantički jaz između čvorova $X_{0,0}$ i $X_{1,3}$ se, umesto jednom direktnom vezom, premošćava preko gustog konvolucionog bloka sa tri konvoluciona sloja, čime se informacija postepeno obogaćuje pre nego što se spoji sa odgovarajućim nivoom dekodera.



Slika 1 UNet++ arhitektura

Implementacija je preuzeta iz biblioteke `segmentation_models.pytorch` [2], koja UNet++ nudi kao dekodeer koji se može kombinovati sa proizvoljnim, unapred obučenim enkoderom npr. ResNet, EfficientNet, itd., čime se omogućava učitavanje težina prethodno treniranih na ImageNet skupu podataka. Ovaj recept je u okviru zadatka prilagođen na dva ključna mesta: (1) ulazni sloj enkodera je izmenjen sa tri (RGB) na jedan kanal, kako bi odgovarao sivim mamografskim snimcima, a težine prvog konvolucionog sloja preuzete sa ImageNet-a su usrednjene po kanalima kako bi transfer učenje i dalje bilo iskorišćeno; (2) izlazni sloj je sveden na jedan kanal sa sigmoid aktivacijom (binarna segmentacija: masa / pozadina).

2.2 Korišćena baza podataka

Za obuku i evaluaciju korišćena je INBreast baza [3], baza mamografskih snimaka prikupljena u univerzitetnoj bolnici u Portu (Portugalija). Baza sadrži snimke sa punim digitalnim mamografskim aparatom (full-field digital mammography), sa preciznim konturama različitih tipova lezija (mase, kalcifikacije, asimetrije, distorzije) koje su obeležili specijalisti i koje su dostupne u XML formatu. U radu su korišćeni isključivo snimci i regioni obeleženi kao tip "Mass"; poligoni koji predstavljaju granice masa su konvertovani u binarne segmentacione maske.

Od svih dostupnih anotiranih slučajeva u bazi, izdvojeni su samo oni koji sadrže bar jednu anotiranu masu, čime je dobijeno 107 snimaka koji pripadaju 50 jedinstvenih pacijenata (od kojih 48 ima više od jednog snimka sa masom). Svaki DICOM snimak je učitao, fotometrijski normalizovan (invertovanje za MONOCHROME1 interpretaciju), a zatim je automatski izdvojen region dojke primenom Otsu praga i najvećeg konture, kako bi se uklonila crna pozadina van same dojke. Intenzitet je dodatno normalizovan klip-ovanjem na 1. i 99. percentil i skaliranjem na opseg [0, 1], a slika i maska su na kraju dovedene na rezoluciju 512×512 piksela (linearna interpolacija za sliku, najbliži sused za masku).

Napomena o identifikaciji pacijenata: pošto je patient_id u ovoj verziji baze anonimizovan, identifikator pacijenta nije mogao pouzdano da se koristi direktno iz DICOM meta-podataka, već je izveden parsiranjem imena samog DICOM fajla (format "<ID_slučaja>_<ID_pacijenta>..."). Ovaj, iz imena fajla izveden identifikator korišćen je kao grupna promenljiva prilikom podele na trening/validaciju/test (GroupShuffleSplit, LeaveOneGroupOut), čime je obezbeđeno da snimci istog pacijenta nikada ne budu istovremeno u trening i test skupu.

2.3 Opis obuke

Model je optimizovan kombinovanom Dice + BCE funkcijom greške, gde je udeo BCE komponente hiperparametar. Dice gubitak meri preklapanje segmentiranog i stvarnog regiona i dobro se nosi sa neravnotežom klasa (mali objekat na velikoj pozadini), dok BCE kažnjava grešku piksel po piksel i pomaže stabilnijem treningu na početku. Kombinacijom se koriste prednosti oba pristupa.

Korišćen je Adam optimizator, uz ReduceLROnPlateau šemu koja automatski smanjuje stopu učenja kada odabrana metrika (validaciona Dice mera ili trening gubitak) prestane da se poboljšava. Time se izbegava ručno podešavanje rasporeda opadanja stope učenja.

Za povećanje raznovrsnosti podataka korišćene su standardne augmentacije (flip, rotacija, promena kontrasta), a opciono i elastične deformacije koje simuliraju prirodnu varijabilnost oblika tkiva. Pošto ove deformacije ponekad mogu uneti nerealne izmene slike, njihovo korišćenje je takođe tretirano kao hiperparametar.

Optimalni hiperparametri (tip gubitka, udeo BCE, stopa učenja, regularizacija, uključivanje elastičnih augmentacija) određeni su pomoću Optuna biblioteke, koja pretragu usmerava ka obećavajućim vrednostima (umesto nasumične/iscrpne pretrage), uz medijan pruner koji rano prekida loše pokušaje radi uštede vremena. Opsezi vrednosti za pretragu nisu birani nasumično, već su suženi na osnovu prethodnih ručnih eksperimenata u kojima su okvirno naslućene razumne vrednosti.

Pretraga je rađena na jednoj podeli po pacijentu (80/20). Nakon odabira konfiguracije, model je testiran na dva načina: (a) ista fiksna podela, radi brze provere i vizuelne inspekcije, i (b) LOPO unakrsna validacija (za svakog od 50 pacijenata model se trenira na ostalima, a testira samo na njemu), što daje nepristrasnu procenu generalizacije. Podela po pacijentu (a ne po pojedinačnim snimcima) je bitna da se izbegne curenje podataka, jer snimci istog pacijenta liče jedni na druge.

Dodatno je ispitano i jednostavno post-procesiranje – uklanjanje malih povezanih regiona (<20 piksela) iz predikcije, što uklanja sitne lažno pozitivne artefakte bez dodatnog treniranja.

Zbog rada u Google Colabu sa T4 GPU-om, korišćena su ograničenja: batch veličina 8, rezolucija 512×512, plići ResNet-34 enkoder, 20 Optuna pokušaja (do 30 epoha uz rano zaustavljanje), i 50–80 epoha za finalne protokole. Ova ograničenja su uzeta u obzir pri tumačenju rezultata.

2.4 Mera uspešnosti algoritma

Kvalitet segmentacije je meren standardnim merama za binarnu segmentaciju: Dice koeficijentom i Jaccard indeksom. Obe mere su računane po pojedinačnjslici, na osnovu broja tačno pozitivnih, lažno pozitivnih, lažno negativnih i tačno negativnih piksela, dobijenih poređenjem binarizovane predikcije sa referentnom maskom. Za protokole sa više slika/pacijenata (LOPO) prikazuju se prosečna vrednost i standardna devijacija, kao i medijana, s obzirom na to da raspodela rezultata po pacijentu, kao što će biti pokazano, nije simetrična.


3. Rezultati i diskusija

3.1 Pretraga hiperparametara

Automatizovanom pretragom (20 pokušaja) kao najbolja konfiguracija izabrana je kombinovana Dice+BCE funkcija greške (udeo BCE komponente ≈ 0.115), stopa učenja $\approx 1.21 \cdot 10^{-4}$, koeficijent regularizacije težina $\approx 1.70 \cdot 10^{-4}$, uz uključene elastične augmentacije (elastic transform i grid distortion). U odnosu na čistu Dice funkciju greške, dodatak BCE komponente je doprineo stabilnijem gradijentu u ranim epohama,

3.2 Konvergencija na jednoj podeli (86 trening / 21 validacija)

Radi provere konvergencije, model sa izabranom konfiguracijom je treniran 80 epoha na jednoj, fiksnoj podeli po pacijentu. Trening Dice raste monotono i stabilizuje se oko 0.79–0.82, dok validacioni Dice, nakon početnog rasta, dostiže maksimum od 0.677 (epoha 66), a potom osciluje u opsegu 0.63–0.67 (slika 2). Razlika između trening i validacione krivih ukazuje na blagi, očekivan stepen preprilagođavanja s obzirom na mali broj trening primera, dok relativna stabilizacija validacione krive posle približno epohe 40 ukazuje da dalje produžavanje obuke iznad 80 epoha na ovoj podeli ne bi donelo značajno poboljšanje.




Slika 2 Kriva gubitka (levo) i Dice koeficijenta (desno) tokom 80 epoha obuke na jednoj trening/validacionoj podeli.


Na istoj podeli je potom treniran i finalni model, koji je na held-out validacionom skupu od 21 slike (pacijenti van treninga) postigao Dice = 0.644 i IoU = 0.561 (tabela 1). Ova vrednost je bliska platou vidljivom na slici 2, ali s obzirom na to da se procena zasniva na samo jednoj podeli i svega 21 slici, ona ima visoku varijansu i ne treba je tumačiti kao pouzdanu ocenu generalizacije modela te je zbog toga korišćena LOPO evaluacija.

3.3 Leave-One-Patient-Out (LOPO) evaluacija

LOPO protokol obuhvata 50 nezavisnih ponavljanja obuke (po jedno za svakog pacijenta), pri čemu se svaki put trenira nov model “od nule” na 49 preostalih pacijenata (50 epoha), a testira na svim snimcima izostavljenog pacijenta. Ovim je svaki od 107 snimaka u bazi tačno jednom ocenjen modelom koji ga tokom obuke nikada nije video. Prosečan Dice iznosi 0.641 ± 0.313 , a prosečan IoU 0.558 ± 0.297 (tabela 1). Vidljivo je da je medijana Dice koeficijenta (0.794) znatno viša od proseka, što ukazuje na asimetričnu raspodelu rezultata po pacijentu.



Slika 3 Dice koeficijent po pojedinačnom izostavljenom pacijentu (LOPO), sortirano rasteće. Isprekidana linija: prosek; tačkasta linija: medijana.



Slika 4 Raspodela Dice koeficijenta (levo) i IoU (desno) preko svih 50 pacijenata u LOPO evaluaciji.


Sa slika 3 i 4 se vidi da većina pacijenata ima Dice iznad 0.6, a značajan broj i iznad 0.85, dok mala grupa od 5 pacijenata ima Dice jednak 0 (masa uopšte nije detektovana), a još nekoliko pacijenata ima Dice u opsegu 0.02–0.6. Ova mala grupa ekstremnih promašaja dovoljna je da značajno obori prosečnu vrednost, dok medijana bolje opisuje tipičan ishod za pacijenta iz baze. Ovakav obrazac je u skladu sa izazovom segmentacije malih i niskokontrastnih lezija u mamografiji. Kvalitativnom proverom najtežih slučajeva (npr. pacijent sa maskama od svega ~750 i ~480 piksela) utvrđeno je da model u potpunosti propušta male, suptilne mase koje se slabo razlikuju od okolnog gustog tkiva, dok velike, jasno ograničene mase segmentira sa visokom preciznošću.

3.4 Uticaj post-procesiranja

Ispitan je i uticaj jednostavnog post-procesiranja odnosno uklanjanja povezanih komponenti manjih od 20 piksela, sa ciljem uklanjanja sitnog, izolovanog šuma u binarnoj predikciji. Efekat je zanemarljiv: u 46 od 50 LOPO foldova rezultat je identičan pre i posle post-procesiranja, a prosečan Dice se menja sa 0.641 na 0.640 (tabela 1). Ovo pokazuje da glavni izvor grešaka modela nisu sitne lažno pozitivne mrlje koje bi post-procesiranje uklonilo, već lažno negativni rezultati odnosno potpuno propuštene mase kod težih slučajeva predhodno opisanih

3.5 Kvalitativna analiza

Vizuelna inspekcija predikcija na held-out primerima (slika 5) potvrđuje kvantitativne nalaze: za velike, dobro ograničene mase visokog kontrasta u odnosu na okolno tkivo (prvi i treći primer), predikcija dobro prati oblik i granicu referentne maske. Za manju, difuznu masu blizu ivice dojke (drugi primer), model potpuno promašuje detekciju, dok za malu ali još uvek relativno kontrastnu masu (četvrti primer) model daje delimično tačnu, ali manju predikciju u odnosu na referentnu masku.



Slika 5 Kvalitativna provera na četiri held-out primera: originalni snimak (gore), referentna maska (sredina), predikcija modela (dole).

3.6 Sumarni pregled rezultata

Protokol evaluacije	Dice	IoU	N (slike / pacijenti)
Jedna podela (held-out, 21 slika)	0.644	0.561	21 slika / 21 pacijenata
LOPO – sirova predikcija	0.641 ± 0.313	0.558 ± 0.297	107 slika / 50 pacijenata
LOPO – nakon post-procesiranja	0.640 ± 0.314	0.558 ± 0.298	107 slika / 50 pacijenata
LOPO – medijana (sirovo)	0.794	0.671	107 slika / 50 pacijenata

Tabela 1. Sumarni pregled Dice i IoU mera za sve isprobane protokole evaluacije.

4. Zaključak

U ovom radu je recept za semantičku segmentaciju iz biblioteke `segmentation_models.pytorch`, zasnovan na arhitekturi UNet++, uspešno prilagođen zadatku segmentacije masa u INBreast bazi mamografskih snimaka. Enkoder je adaptiran za jednokanalne ulaze uz zadržavanje ImageNet transfera znanja, definisan je odgovarajući tok obrade podataka, a hiperparametri su odabrani automatizovanom pretragom.

Evaluacija koja koristi grupisanje po pacijentu (LOPO, 50 nezavisnih pacijenata) pokazuje da model postiže solidne performanse na tipičnim, jasno izraženim masama (medijana Dice ≈ 0.79), ali da značajno slabije prepoznaje mali broj malih, niskokontrastnih lezija, koje su odgovorne za nekoliko potpunih promašaja i za znatno nižu prosečnu vrednost (Dice ≈ 0.64) u odnosu na medijanu. Post-procesiranje uklanjanjem sitnih komponenti nije donelo poboljšanje, čime je potvrđeno da su dominantan izvor greške lažno negativni, a ne lažno pozitivni rezultati.

Dobijeni rezultati treba tumačiti uz ograničenja nametnuta raspoloživim resursima, obuka je izvedena u okruženju Google Colab sa GPU-om tipa T4, što je ograničilo veličinu serije, rezoluciju ulazne slike i obim pretrage hiperparametara, kao i da je identifikator pacijenta, usled anonimizacije DICOM meta-podataka, morao biti izveden iz imena DICOM fajla, a ne iz standardnog DICOM atributa. Kao pravci daljeg rada moglo bi se razmatrati: korišćenje dubljeg enkodera i veće rezolucije ulaza, kao i uvećanje veličine trening skupa (dodatne baze ili sintetička augmentacija) radi boljeg prepoznavanja malih, suptilnih masa.

Literatura

- [1] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, and J. Liang, "UNet++: A Nested U-Net Architecture for Medical Image Segmentation," arXiv:1807.10165, Jul. 2018. doi: 10.48550/arXiv.1807.10165.
- [2] P. Iakubovskii et al., "segmentation_models.pytorch," GitHub repository, https://github.com/qubvel-org/segmentation_models.pytorch.
- [3] I. C. Moreira, I. Amaral, I. Domingues, A. Cardoso, M. J. Cardoso, and J. S. Cardoso, "INbreast: Toward a Full-field Digital Mammographic Database," Academic Radiology, vol. 19, no. 2, pp. 236–248, 2012. doi: 10.1016/j.acra.2011.09.014.