

Semantička segmentacija mamografskih slika

na osnovu recepta datog na [https://github.com/qubvel-org/
segmentation_models.pytorch](https://github.com/qubvel-org/segmentation_models.pytorch) (UNet++)

Teodora Todorović E9 2/2025

Sadržaj


- Motivacija i problem
- Koncept UNet++ arhitekture
- Biblioteka `segmentation_models.pytorch`
- Prilagođavanje modela za INBreast bazu
- Priprema podataka i obuka
- Rezultati (LOPO evaluacija)
- Diskusija, ograničenja i zaključak

Zašto je bitna segmentacija masa?

- Rano otkrivanje karcinoma dojke zavisi od preciznog uočavanja masa na mamografiji
- Ručni pregled snimaka je vremenski zahtevan i podložen subjektivnoj proceni
- Automatska (piksel-po-piksel) segmentacija je osnova sistema za računarski potpomognutu dijagnostiku (CAD)
- Izazovi specifični za mamografiju:
 - nejasne, difuzne granice masa
 - mali objekti i jaka neuravnoteženost klasa
 - relativno mala, teško dostupna baza anotiranih snimaka

UNet++

- Ugnježdena (nested) varijanta klasične U-Net arhitekture za segmentaciju
- Jednostavne “skip” veze zamenjene gustom mrežom ugnježenih konvolucionih blokova
- Svaki blok kombinuje mape osobina sa istog nivoa enkodera i sa susednih, plićih nivoa dekodera
- Cilj: smanjiti semantički jaz između mapa osobina enkodera i dekodera pre njihovog spajanja
- Podržava dubok nadzor (deep supervision) na više izlaznih grana



Biblioteka segmentation_models.pytorch

- Preko 10 arhitektura za segmentaciju: Unet, UnetPlusPlus, DeepLabV3+, FPN, PSPNet, ...
- Zajednički API — arhitektura i enkoder se biraju kao parametri, bez menjanja ostatka koda
- Stotine unapred obučenih enkodera (ResNet, EfficientNet, MobileNet, ...)
- Ugrađena podrška za transfer učenje (ImageNet težine) i standardne mere/gubitke (Dice, IoU, Focal, ...)

```
import segmentation_models_pytorch as smp

model = smp.UnetPlusPlus(
    encoder_name="resnet34",
    encoder_weights="imagenet",
    in_channels=3,
    classes=1,
    activation=None,
)
```

Prilagođavanje modela za mamografske snimke

- Mamografski snimci su jednokanalni (grayscale); ImageNet enkoderi očekuju 3 (RGB) kanala
- Ulazni sloj enkodera promenjen na in_channels=1
- Težine prvog konvolucionog sloja (ImageNet) usrednjene po RGB kanalima
- Izlazni sloj: 1 kanal (sigmoid nad logitima), binarna maska masa/pozadina

```
model = smp.UnetPlusPlus(encoder_name="resnet34",
                          encoder_weights=None, in_channels=1, classes=1)

pretrained = tv_models.resnet34(weights=IMAGENET1K_V1)
rgb_w = pretrained.state_dict()["conv1.weight"]
matched["conv1.weight"] = rgb_w.mean(dim=1, keepdim=True)

model.encoder.load_state_dict(matched, strict=False)
```

INBreast baza podataka

- Javno dostupna baza punih digitalnih mamografskih snimaka (univerzitetska bolnica, Porto)
- Anotacije lezija (mase, kalcifikacije, asimetrije, distorzije), poligoni u XML formatu
- Korišćeni samo snimci sa anotiranom masom: 107 slika / 50 jedinstvenih pacijenata
- ID pacijenta izveden iz imena DICOM fajla, jer su DICOM meta-podaci anonimizovani

Tok obrade podataka

- 1 Učitavanje DICOM snimka i korekcija fotometrijske interpretacije (MONOCHROME1)
- 2 Pretvaranje XML poligona masa u binarnu segmentacionu masku
- 3 Automatsko kadriranje regiona dojke (Otsu prag + najveći kontura)
- 4 Normalizacija intenziteta (1.–99. percentil, skaliranje na $[0,1]$)
- 5 Promena rezolucije slike i maske na 512×512 piksela

Augmentacija podataka i funkcija greške

Augmentacije

- Horizontalno i vertikalno preslikavanje
- Rotacija ($\pm 20^\circ$)
- Promena kontrasta i osvetljenja
- Opciono: elastične deformacije i grid distortion (hiperparametar)

Funkcija greške

- Dice loss (mera preklapanja regiona)
- BCE loss (binarna unakrsna entropija po pikselu)
- Kombinovana Dice + BCE funkcija greške
- Udeo BCE komponente — hiperparametar (najbolje ≈ 0.115)


Obuka modela i pretraga hiperparametara

- Optimizator Adam + ReduceLROnPlateau (opadanje stope učenja na platou)
- Automatizovana pretraga hiperparametara: Optuna, 20 pokušaja, medijan pruner
- Pretraživano: tip funkcije greške, augmentacije, stopa učenja, L2 regularizacija
- Najbolja konfiguracija: Dice+BCE (udeo BCE ≈ 0.115), lr $\approx 1.21 \cdot 10^{-4}$, weight decay $\approx 1.7 \cdot 10^{-4}$, elastične augmentacije uključene
- Obuka izvedena na Google Colab (GPU T4), batch size 8, rezolucija 512×512

Protokoli evaluacije

- Mere uspešnosti: Dice koeficijent i IoU (Jaccard indeks), računati po slici
- Protokol 1 — jedna podela po pacijentu (80% / 20%): brza provera konvergencije
- Protokol 2 — Leave-One-Patient-Out (LOPO): 50 nezavisnih ponavljanja, svaki pacijent testiran tačno jednom, van treninga
- Dodatno ispitan uticaj post-procesiranja predikcije (uklanjanje povezanih komponenti manjih od 20 piksela)


Rezultati: konvergencija obuke



Trening/validacioni gubitak i Dice koeficijent tokom 80 epoha (jedna podela po pacijentu).


Najbolji validacioni Dice = 0.677 (epoha 66); nakon toga vrednost osciluje bez značajnog daljeg rasta.

Rezultati: LOPO evaluacija po pacijentu



- 50 pacijenata, svaki testiran modelom koji ga nikad nije video
- Prosek Dice = 0.641 ± 0.313
- Medijana Dice = 0.794
- Nekoliko potpunih promašaja (Dice ≈ 0) obara prosek

Rezultati: raspodela i sumarni pregled




Raspodela Dice i IoU preko svih pacijenata (LOPO)

Protokol	Dice	IoU
Jedna podela (held-out)	0.644	0.561
LOPO – sirovo (prosek)	0.641 ± 0.313	0.558 ± 0.297
LOPO – post-procesirano	0.640 ± 0.314	0.558 ± 0.298
LOPO – medijana	0.794	0.671

Post-procesiranje (uklanjanje sitnih komponenti) gotovo da ne menja rezultat, greške su uglavnom lažno negativne (propuštene mase).

Kvalitativna analiza predikcija



Originalni snimak (gore), referentna maska (sredina), predikcija modela (dole).

Diskusija i ograničenja

- Mali skup, više snimaka pripada jednom pacijentu
- Post-procesiranje nije poboljšalo rezultate, dominantan izvor greške su propuštene mase, ne šum
- Glavni preostali izazov: male, suptilne mase niskog kontrasta u odnosu na okolno tkivo
- Obuka na Google Colab (GPU T4) ograničila je veličinu serije, rezoluciju slike i obim pretrage hiperparametara
- ID pacijenta je, usled anonimizacije DICOM meta-podataka, morao biti izveden iz imena DICOM fajla

Zaključak

- Opšti recept za semantičku segmentaciju iz `segmentation_models.pytorch` uspešno je prilagođen jednokanalnim mamografskim snimcima (UNet++, ResNet-34 enkoder)
- LOPO evaluacija na 50 nezavisnih pacijenata: medijana Dice ≈ 0.79 na tipičnim masama, ali znatno slabije rezultate na malim/suptilnim lezijama
- Post-procesiranje ne rešava problem
- Pravci daljeg rada: dublji enkoder, veći skup podataka

Literatura

- [1] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh, J. Liang, “UNet++: A Nested U-Net Architecture for Medical Image Segmentation,” arXiv:1807.10165, 2018.
- [2] P. Iakubovskii et al., “segmentation_models.pytorch,” GitHub, github.com/qubvel-org/segmentation_models.pytorch
- [3] I. C. Moreira et al., “INbreast: Toward a Full-field Digital Mammographic Database,” Academic Radiology, 19(2), 236–248, 2012.